

英文社交媒体文本中的抑郁倾向识别

Python 课程设计项目汇报



汇报人：任冉 | 萧准

第七组

01 研究背景：为什么做这个项目？



01. 社交媒体的普及

社交媒体已成为人们表达真实情绪的主要窗口，海量的网络文本数据沉淀了个体的心理状态轨迹，为非侵入式的心理健康分析提供了全新的、极具潜力的数据源。



02. 传统筛查的局限性

传统方式严重依赖人工访谈，存在成本高昂、效率低下的问题；且受社会污名化和资源分布不均影响，难以实现大规模人群的普筛与早期发现，导致许多潜在需求被忽视。



03. 项目核心目标

利用机器学习技术自动分析社交媒体文本中的语言模式与情感特征，构建高效、低成本的抑郁倾向识别模型，为心理危机的早期预警与干预提供科学、客观的决策支持。

02 项目总体架构



01. 文本输入

接入多源非结构化文本数据，建立标准化输入接口，为后续处理提供基础数据源。



02. 数据预处理

执行清洗、去噪、分词与标准化操作，过滤无效信息，提升数据质量与一致性。



03. 特征提取

融合 TF-IDF 权重、VADER 情感分析与专业领域词典，构建多维度高价值特征矩阵。



04. 模型训练与迭代

选用最优分类模型进行训练，基于交叉验证持续调优，确保模型具备强泛化能力。



05. 概率校准

通过 Platt Scaling 等方法校准模型输出概率，使其更贴合真实风险分布，提升决策参考价值。



06. 风险分层分级

依据校准后的概率阈值，将样本划分为高、中、低不同风险等级，为干预策略提供精准依据。



07. 可视化 GUI 展示

开发交互式图形界面，直观呈现风险结果、特征权重与分层详情，实现技术结果的业务落地。

03 数据集介绍



数据集来源

本研究采用公开的心理健康文本数据集，数据源自全球最大的数据科学社区 Kaggle。该数据集收集了真实的用户心理状态描述文本，覆盖多种情绪类别，样本质量高且具有广泛的代表性，为模型训练提供了坚实基础。

原始标签体系

数据集包含四种核心情绪标签：抑郁 (Depression)、正常 (Normal)、焦虑 (Anxiety) 以及自杀倾向 (Suicidal)，完整覆盖了从心理健康到严重心理危机的不同状态，构建了多维度的心理文本样本库。

二分类任务定义

为聚焦核心问题，将多分类任务重构为二分类任务：将“抑郁 (Depression)”设定为正类，代表目标检测对象；将“正常”、“焦虑”和“自杀倾向”合并为负类，以此简化模型复杂度，提升对抑郁状态的识别精度与召回率。

数据集划分	样本数量 (条)	用途说明
训练集 (Train)	4,893	用于模型核心参数的学习与拟合
验证集 / 测试集 (Val / Test)	1,224 / 1,530 (总计 2,754)	验证集调优超参数，测试集评估泛化能力

04 数据存储与管理



为什么选择 SQLite?

SQLite 是轻量级嵌入式数据库，无需独立服务器，可无缝集成 Python 程序。它支持高效的 SQL 查询，能结构化管理大规模文本数据，是本项目的最优选择。

结构化数据库划分

train.db 训练集库

存储模型训练的核心语料数据，数据量最大，结构完整。

val.db & test.db 验证与测试库

独立存储验证集与测试集数据，严格隔离，确保评估结果客观公正。

不使用 Excel 进行数据管理的原因

Excel 适合人工小规模操作，难以支撑程序批量读写与复杂查询。SQLite 作为嵌入式数据库，在处理大规模文本数据的效率、并发和结构化管理上优势显著。

核心优势：程序驱动，高效管理

05 特征工程：文本如何变成机器能理解的数据？




01. TF-IDF 文本向量化

将文本转换为高维稀疏数值向量，例如句子“I feel sad today”可转化为[0.15, 0.76, 0.22,...]，让机器学习模型能够直接解析与处理语义信息。



02. VADER 情感特征提取

提取文本的积极(Positive)、消极(Negative)、中性(Neutral)及综合情感得分(Compound)，为模型补充关键的情感极性维度，增强分析深度。



03. 专业心理健康词典增强

引入包含depression、suicide等关键词的EMNLP17专业词典，统计高频心理相关词汇出现频率，显著提升模型对抑郁倾向文本的识别敏感度。

06 模型选择

Logistic Regression (逻辑回归)

模型结构简单，训练速度快，且具备极佳的可解释性，能够直观分析各特征对预测结果的权重影响，便于后续的特征工程优化。

Random Forest (随机森林)

集成学习方法，构建多棵决策树并通过投票机制输出结果。能够有效处理非线性数据，鲁棒性强，对异常值和噪声有较好的容忍度。

LinearSVC (线性支持向量机)

专为高维稀疏数据设计，在文本分类等场景中表现优异。通过最大化分类间隔实现分类，通常具有很强的泛化能力，不易过拟合。


XGBoost (极端梯度提升)

高效的梯度提升树模型，通过不断迭代优化损失函数来提高精度。具有正则化项防止过拟合，是数据科学竞赛和工业界的主流选择。



最终决策：我们选择了在验证集上综合表现最优的模型——*逻辑回归*作为系统核心，平衡了预测精度与工程落地效率。

07 概率校准：为什么需要Platt Scaling?



以温度计为喻，概率校准让模型输出从“定性”的冷热判断，转变为“定量”的具体温度值，提供更精细的决策依据。

01. 核心痛点：SVM模型的“局限性”

传统SVM等模型默认仅输出离散的类别标签（如“抑郁/非抑郁”），无法直接提供预测结果的**置信度概率**，导致我们无法量化判断的确定性程度，难以进行风险分级。

02. 关键技术：Platt Scaling 概率校准

通过引入**CalibratedClassifierCV**类，利用Platt Scaling方法对模型原始输出进行逻辑斯蒂回归拟合，将输出值映射到 $[0, 1]$ 的概率区间，赋予预测结果统计学上的概率意义。

03. 实践价值：精细化的风险分层管理

校准后的“抑郁概率值”（如2.97%低风险、91%高风险），为临床干预提供了可量化的依据，实现了从“一刀切”分类到“梯度化”风险评估的转变。

08 模型优化过程



数据清洗：夯实基础

执行严格的预处理流程，删除重复文本记录以避免数据冗余；清理无关字符、格式错误等噪声数据，确保输入数据的纯净度与一致性。



样本均衡：过采样策略

采用 RandomOverSampler 对数量较少的抑郁样本进行随机过采样，有效平衡数据集分布，缓解模型因样本不均产生的偏向性学习问题。



训练机制：权重自适应

在模型训练中启用 class_weight 参数，为少数类别的样本赋予更高的损失权重，引导模型更加关注易被忽视的关键抑郁样本特征。



阈值调节：平衡精准与召回

动态调整分类决策的概率阈值，不再局限于默认的 0.5 分界点。核心目标是在精确率和召回率之间取得最佳平衡，最大限度降低对高风险抑郁样本的漏判概率，保障筛查的敏感性。



消融实验：特征有效性验证

对比了 TF-IDF、TF-IDF+VADER、TF-IDF+VADER+专业词典等组合。实验结果表明，融合情感分析工具与领域专业词典的多维度特征方案，能最大程度捕捉文本中的情绪信号，模型性能最优。

09 实验结果

Accuracy (准确率)

0.888

Recall (召回率)

0.979


F2 Score (F2分数)

0.945

ROC-AUC (曲线下面积)

0.977

模型在测试集上展现出均衡且优异的性能表现，各项核心指标均达到预期标准，其中高召回率和AUC值充分验证了模型在抑郁筛查场景中的适用性。



低漏判率优势


Recall值达0.979，意味着97.9%的真实抑郁样本被成功识别，极低的漏判率对筛查工具的有效性至关重要。




强样本区分力

AUC值0.977接近1，表明模型具备极强的分类能力，能够清晰、准确地将抑郁样本与非抑郁样本区分开来。

10 系统演示



交互式情感分析面板，支持即时文本输入与反馈。



批量文本分析与文档上传功能，支持多语言检测配置。



可视化结果展示，直观呈现情感倾向与置信度评分。

系统整合了 RoBERTa 模型与 VADER 情感分析工具，通过用户友好的图形界面，实现从原始文本输入到心理健康风险分层与情感量化的一站式智能评估。

用户输入示例

"i love u so much"
"i ate cake this evening"

风险等级 (Risk Tier)

低风险

抑郁概率

2.97%

模型综合评分

VADER情感

+0.64

积极倾向显著

11 总结与展望

01 关键成果：全流程闭环构建

✅ 完成多源文本数据的清洗、标注与标准化管理，建立统一数据集。

✅ 提取TF-IDF等统计特征与句法特征，构建多维度文本表征体系。

✅ 对比SVM、随机森林等模型，实现概率校准与精细化风险分层。

✅ 开发交互式GUI系统，实现从输入到分析结果的可视化演示。

02 研究局限：挑战与待解问题

语言限制

当前模型仅适配英文文本分析，未处理中文分词与语义特征，适用场景受限。

数据单一与泛化不足：实验数据来源较为单一，可能存在样本偏差；模型在跨领域（如新闻与社交媒体）文本上的鲁棒性与泛化能力仍需进一步验证与优化。


03 未来展望：技术迭代与应用扩展

模型升级

引入BERT等预训练语言模型，深度挖掘文本语义，提升特征表达能力。

多语言与Web化部署：扩展中文社交媒体文本处理能力，解决分词与语境适配问题；将系统重构为Web应用，降低使用门槛，实现多端访问与更广泛的服务。

BERT (Ours)



核心技术方向

BERT作为双向Transformer预训练模型，能有效捕捉上下文语义，是突破当前传统机器学习模型瓶颈、实现更精准文本分析的关键路径。